

## Алгоритм шинжилгээ, зохиомж 2 **Genetic algorithm, Critical nodes тайлан**

Оюутан: Т.Билэгүүн, Д.Балжинням, Б.Бадрангийх, Г.Батзориг

Genetic algorithm нь байгалийн шалгарал, генетикийн үйл явцаас сэдэвлэсэн хайлт, оновчлолын арга юм. Уг алгоритм нь өгөгдсөн асуудлын оновчтой шийдлийг олоход хэрэглэгддэг.

Genetic algorithm-д боломжит шийдлүүдийн population (популяци буюу individuals эсвэл хромосом гэж нэрлэдэг) хамгийн сайн шийдлийг олохын тулд үе дамждаг. Алгоритм нь нөхөн үржихүй (reproduction), кроссовер, мутаци зэрэг биологийн процессуудыг дуурайж, популяцийг давталттайгаар сайжруулдаг.

### **Genetic algorithm хэрхэн ажилладаг вэ?**

**Initialization (эхлэл):** Алгоритм нь санамсаргүй хүмүүсийн анхны популяци үүсгэх замаар эхэлдэг. Хувь хүн бүр асуудлын боломжит шийдлийг төлөөлдөг.

**Evaluation (үнэлгээ):** Популяцийн хувь хүн бүрийг шийдлийн чанарыг тодорхойлдог фитнесийн функцийг ашиглан үнэлдэг. Фитнесийн функц нь асуудлын зорилго эсвэл зорилгыг тодорхойлдог.

**Selection (сонголт):** Хувь хүмүүсийг бие бялдрын хувьд одоогийн хүн амын дундаас сонгоно. Өндөр бие бялдартай хүмүүс нөхөн үржихүйд сонгогдох магадлал өндөр байдаг. Энэ үйл явц нь ихэвчлэн тэмцээн сонгох эсвэл рулет дугуй сонгох зэрэг арга техникийг ашиглан хэрэгждэг.

**Reproduction (нөхөн үржихүй):** Сонгогдсон бодгальуудыг дараагийн хойч үедээ үр удмаа бий болгоход ашигладаг. Энэ нь кроссовер болон мутацийн үйлдлээр хийгддэг.

- Кроссовер: Эцэг эхийн хоёр хувь нэгдэж, генетикийн мэдээлэл солилцох замаар нэг буюу хэд хэдэн үр удмыг бий болгодог. Энэ нь бэлгийн нөхөн үржихүйн үйл явцыг дуурайдаг бөгөөд эцэг эхийн хооронд шинж чанар солилцдог. Кроссовер цэг нь генетикийн материалыг хаана солилцохыг тодорхойлдог.
- Мутаци: Ургийн удамшлын материалд санамсаргүй байдлаар бага зэрэг өөрчлөлт ордог. Энэ нь генетикийн олон янз байдлыг нэвтрүүлж, алгоритмыг орон нутгийн оновчтой байдалд оруулахаас сэргийлдэг.

**Replacement (орлуулах):** Үр удмын популяци нь алгоритмын загвараас хамааран одоогийн популяцийг бүхэлд нь эсвэл хэсэгчлэн орлоно. Дараагийн үе нь бүрэлдэж байна.

**Termination (дуусгах):** Алгоритм нь тодорхой тооны үеийн туршид эсвэл дуусгавар болох шалгуурыг хангах хүртэл үнэлгээ, сонгох, хуулбарлах, солих

алхмуудыг давтдаг. Дуусгах шалгуур нь бие бялдын чийрэгжилтийн хангалттай түвшинд хүрэх, эсвэл урьдчилан тодорхойлсон хугацааны хязгаар байж болно.

### ***OCLinks.txt файлд байгаа графын мэдээлэл***

Оройн тоо 1899, ирмэгийн тоо 13939 ширхэг байсан. Үүнээс connected component нь нийт 4 ширхэг байсан.

```
print(G)

counter = 0
connected_components = nx.connected_components(G)
print("Connected Components:")
for component in connected_components:
    counter += 1
    print(component)
print("Connected Components count: ", counter)
print("All paths count: ", findAllPathsCount(G))
```

  

```
Graph with 1899 nodes and 13838 edges
Connected Components:
{0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15}
{228, 229}
{1796, 1797}
{1811, 1812}
Connected Components count: 4
All paths count: 1790781.0
```

### ***Networkx сангийн функц ашиглах нь***

Энэхүү зурагт үзүүлснээр бид networkx сангийн articulation\_points() функцийг ашиглан critical nodes-үүдээ олох боломжтой. Мөн connected\_components() функцээр хуваагдсан sub graph-уудаа тоолох боломжтой юм.

```

def remove_critical_nodes(G):
    critical_nodes = nx.articulation_points(G)
    modified_graph = G.copy()

    for node in critical_nodes:
        modified_graph.remove_node(node)

    return modified_graph

modified_graph = remove_critical_nodes(G);
print(modified_graph);

counter = 0
connected_components = nx.connected_components(modified_graph)

for component in connected_components:
    counter += 1
    # print(component)
print("Connected Components count: ", counter)
print("All paths count: ", findAllPathsCount(modified_graph))

Graph with 1679 nodes and 5209 edges
Connected Components count: 508
All paths count: 674551.0

```

### ***Articulation point***

График дахь articulation цэгүүдийг олох алгоритм нь DFS алгоритм дээр суурилж бичигдсэн функц юм. Графын оройг түүний ирмэгүүдийн хамт устгахад графикт байгаа холбогдсон компонентүүдийн тоог нэмэгдүүлдэг.

### ***Articulation point reference***

Hopcroft, J.; Tarjan, R. (1973). "Efficient algorithms for graph manipulation". Communications of the ACM 16: 372–378. doi:10.1145/362248.362272

### ***Genetic algorithm implementation (Үр дүн SEQ = 1352195.0, 6 минут)***

```

import random
from collections import defaultdict

def read_graph_from_file(file_path):
    graph = defaultdict(set)
    with open(file_path, 'r') as f:
        num_nodes = int(f.readline().strip())
        for line in f:
            node, neighbors = line.strip().split(':')
            node = int(node)
            neighbors = set(map(int, neighbors.split()))
            graph[node] = neighbors
    return graph

```

```

def fitness_function(individual, graph, memo):
    individual_key = tuple(sorted(individual))
    if individual_key in memo:
        return memo[individual_key]

    num_components = get_number_of_connected_components(graph)
    graph_copy = remove_nodes(graph, individual)
    num_components_after_removal =
get_number_of_connected_components(graph_copy)

    fitness = num_components_after_removal - num_components
    memo[individual_key] = fitness
    return fitness

def get_number_of_connected_components(graph):
    visited = set()
    num_components = 0

    for node in graph:
        if node not in visited:
            dfs(graph, node, visited)
            num_components += 1
    return num_components

def dfs(graph, node, visited):
    visited.add(node)
    for neighbor in graph[node]:
        if neighbor not in visited:
            dfs(graph, neighbor, visited)

def remove_nodes(graph, nodes):
    modified_graph = graph.copy()
    for node in nodes:
        if node in modified_graph:
            del modified_graph[node]
            for neighbor in modified_graph:
                modified_graph[neighbor].discard(node)
    return modified_graph

def generate_initial_population(graph, population_size,
num_critical_nodes):
    nodes = list(graph.keys())
    return [random.sample(nodes, num_critical_nodes) for _ in
range(population_size)]

```

```

def crossover(parent1, parent2):
    if len(parent1) == 1 or len(parent2) == 1:
        return parent1, parent2

    crossover_point = random.randint(1, min(len(parent1),
len(parent2)) - 1)
    child1 = parent1[:crossover_point] +
parent2[crossover_point:]
    child2 = parent2[:crossover_point] +
parent1[crossover_point:]
    return child1, child2

def mutate(individual, mutation_rate, graph):
    nodes = list(graph.keys())
    individual = [random.choice(nodes) if random.random() <
mutation_rate else i for i in individual]
    return individual

def genetic_algorithm(graph, num_critical_nodes,
population_size=100, generations=100, mutation_rate=0.15):
    population = generate_initial_population(graph,
population_size, num_critical_nodes)
    memo = {}
    best_individual = max(population, key=lambda x:
fitness_function(x, graph, memo))
    best_fitness = fitness_function(best_individual, graph,
memo)

    for generation in range(generations):
        print(generation, "th change")
        new_population = []
        for _ in range(population_size // 2):
            parent1, parent2 = random.sample(population, 2)
            child1, child2 = crossover(parent1, parent2)
            child1 = mutate(child1, mutation_rate, graph)
            child2 = mutate(child2, mutation_rate, graph)
            new_population.extend([child1, child2])

        population = new_population
        current_best_individual = max(population, key=lambda x:
fitness_function(x, graph, memo))
        current_best_fitness =
fitness_function(current_best_individual, graph, memo)

```

```

    if current_best_fitness > best_fitness:
        best_individual = current_best_individual
        best_fitness = current_best_fitness

return best_individual, best_fitness

```

### **Genetic algorithm implementation (Үр дүн 845678, 5 минут)**

#### **Уг алгоритмын ажиллагаа буюу pseudocode:**

1. Networkx сангийн articulation\_nodes() ашиглаад хамгийн ашигтай critical nodes-үүдээ олно.
2. Олсон оройнуудаасаа mutation функцаа авч ашиглаж байгаа. Ингэснээр random орой авч ашигласнаар хамаагүй efficient буюу үр ашигтай юм.
3. Population generate хийх
4. Evolution үйл явц
  - a. Crossover хэрэгжүүлэлт
    - i. Дурын хоёр дараалал сонгож аваад тэрнийхээ эхний дурын хэсгийг сонгож нөгөөгийнхөө эхний хэсэг дээр сольж тавьсан.
  - b. Mutation хэрэгжүүлэлт
    - i. Mutation дурын нэг дараалал сонгож тэрний дурын нэг оройг нь дурын нэг оройгоор сольж байгаа.
  - c. Холболт дээр үндэслэн population-ыг ангилах

```

i=0
while i<iteration:
    i+=1
    j=0
    while j<n//2:
        j+=1
        rand_gene = random.randint(0, n-1)
        new_seq = population[rand_gene].seq.copy()
        l=0
        while l<10:
            l+=1
            mut_point = random.randint(0, k-1)
            cod = random.choice(node_list)
            while cod in new_seq:
                cod = random.choice(node_list)
            new_seq[mut_point] = cod
        new_seq.sort()
        check=0
        for s in population:
            if new_seq == s.seq:

```

```

        check+=1
    if new_seq in used :
        check+=1
    else :
        used.append(new_seq)
    if check > 0 :
        j -=1
    else:
        new_gene = Gene(new_seq, zor(graph.subgraph([element for
element in node_list if element not in new_seq])))
        population.append(new_gene)

population.sort(key=lambda x: x.cc)
population = population[:n]
j=0
while j< n//10:
    j+=1
    rand_gene1 = random.randint(0, n//10- 1)
    rand_gene2 = random.randint(n//10, n - 1)
    crossover_point = random.randint(0, k-1)
    new_seq = population[rand_gene1].seq.copy()
    new_seq[crossover_point:] =
population[rand_gene2].seq[crossover_point:].copy()
    new_seq.sort()
    check=0
    for s in population:
        if new_seq == s.seq:
            check+=1
    if new_seq in used :
        check+=1
    else :
        used.append(new_seq)
    dup = {x for x in new_seq if new_seq.count(x) > 1}
    if len(dup) > 0 :
        check+=1
    if check>0 :
        j -=1
    else :
        new_gene = Gene(new_seq, zor(graph.subgraph([element for
element in node_list if element not in new_seq])))
        population[rand_gene2] = new_gene
population.sort(key=lambda x: x.cc)
print("->%d : %d" %(i, population[0].cc))

```

```
ccs.append(population[0].cc)
```

**Үр дүн  $k=190$ , хугацаа = 7 минут:**

```
→1485 : 669947
→1486 : 669947
→1487 : 669947
→1488 : 668790
→1489 : 668790
→1490 : 669947
→1491 : 669947
→1492 : 669947
→1493 : 669947
→1494 : 669947
→1495 : 669947
→1496 : 669947
→1497 : 669947
→1498 : 669947
→1499 : 669947
→1500 : 669947
```

**Үр дүн  $k = 380$ , хугацаа = 9 минут:**

```
→1474 : 441374
→1475 : 441374
→1476 : 441374
→1477 : 441374
→1478 : 441374
→1479 : 441374
→1480 : 441374
→1481 : 441374
→1482 : 441374
→1483 : 441374
→1484 : 441374
→1485 : 441374
→1486 : 441374
→1487 : 441374
→1488 : 441374
→1489 : 441374
→1490 : 441374
→1491 : 441374
→1492 : 441374
→1493 : 441374
→1494 : 441374
```

“Efficiently identifying critical nodes in large complex networks Mario Ventresca<sup>1\*</sup> and Dionne Aleman<sup>2</sup>” материалын үр дүнтэй харьцуулахад Бидний гаргасан үр дүн уг үр дүнг гүйцэж чадахгүй харагдаж байна.



<b>Table 4 Comparison of the CNDP objective value after removing 10% and 20% of vertices from each network in Table 1</b>						
<b>Problem</b>	<b>K</b>	<b>SEQ</b>	<b>Degree</b>	<b>PageRank</b>	<b>Authority</b>	<b>MIS</b>
Comnat	2313	58,796,393	103,398,683	87,630,163	126,804,602	NA
	4627	83,686	90,610	92,242	7,399,785	NA
Ego	404	2,717,347	5,339,614	3,816,109	6,320,816	2,192,636
	808	1,848,740	2,070,535	2,886,709	3,438,031	903,441
Flight	294	322,527	484,331	467,962	1,014,305	77,777
	588	1,457	1,698	1,715	1,567	2,626
Powergrid	494	22,182	51,508	212,369	56,815	25,253
	988	3,639	4,580	14,744	3,771	5,378
Relativity	524	224,010	1,628,337	302,309	3,382,195	23,620
	1,048	4,089	4,896	9,023	6,390	6,163
Oclinks	190	637,936	785,662	758,328	835,297	746,085
	380	218,215	258,277	246,876	306,289	402,824
SEQ-based results are those obtained by the proposed algorithm. The MIS-based approach was unable to arrive at solutions within 40 h for the conmat networks.						

### **Ашигласан материал**

- Evolutionary algorithms and their applications to engineering problems Adam Slowik<sup>1</sup> • Halina Kwasnicka<sup>2</sup>
- Efficiently identifying critical nodes in large complex networks Mario Ventresca<sup>1\*</sup> and Dionne Aleman<sup>2</sup>
- connected components — NetworkX 3.1 documentation
- articulation points — NetworkX 3.1 documentation